

Projekt ML - Detektor Phishingu

Dominika Gwarda, Mateusz Katafiasz, Aleksandra Ponikowska

<https://github.com/domgwarda/ml-project>

March 24, 2026

Detektor phishingu

Cele projektu

- ▶ Klasyfikujemy linki na podstawie treści URL: phishing czy nie.
- ▶ Taki model mógłby być stosowany do ostrzegania użytkownika przed klikaniem w niebezpieczne linki.
- ▶ Bardziej zależy nam na poprawnej klasyfikacji phishingu niż nie phishingu: $\text{recall} > \text{accuracy}$.

Cel

Target i Baseline

- ▶ Podczas naszego testu ludzie klasyfikowali linki z dokładnością 67%. Nabierali się na phishing w 34%.
- ▶ W praktyce użytkownicy są bardziej bezmyślni.
- ▶ Najlepsze narzędzia w internecie mają powyżej 90% accuracy.

Wyniki badania

Ludzki performance




Figure: Confusion matrix

Wyniki badania

Informatycy vs nie-informatycy




Figure: Confusion matrix

Wyniki badania

Performance ludzki

Wszyscy badani:

- ▶ *Accuracy*: **67%**
- ▶ *Recall*: **67%**

Informatycy

- ▶ *Accuracy*: 74%
- ▶ *Recall*: 69%

Nie-informatycy

- ▶ *Accuracy*: 64%
- ▶ *Recall*: 65%



Metodologia

Feature engineering

Wynik feature engineeringu:

- ▶ *Czy Https?*
- ▶ Liczba znaków w linku/domenie ('.', ',', '/', digits, etc)
- ▶ Podział domeny na subdomene + domene + suffix q (*tld*)
- ▶ Dla subdomeny: *czy jest www?, czy zawiera popularna domene/subdomene?*
- ▶ Dla domeny: *czy zawiera popularna domene/suffix?, jakie jest najdluzsze podslowo domeny?, jak bardzo podobne jest do jakiejś popularnej domeny?*
- ▶ Dla suffixu: *czy jest .com?, czy jest rozszerzeniem jakiegoś państwa?, czy należy do "niebezpiecznych" tld?*

Metodologia

Levenstein distance

Computing Levenshtein distance – 4

$$D(i,j) = \min \begin{cases} D(i-1,j-1) + d(s_i,t_j) & //subst/copy \\ D(i-1,j)+1 & //insert \\ D(i,j-1)+1 & //delete \end{cases}$$


A *trace* indicates where the min value came from, and can be used to find edit operations and/or a best *alignment* (may be more than 1)

	C	O	H	E	N
M	1	2	3	4	5
C	1	2	3	4	5
C	2	3	3	4	5
O	3	2	3	4	5
H	4	3	2	3	4
N	5	4	3	3	3

Figure: <https://www.linkedin.com/pulse/levenshtein-distancesearch-engine-davronbek-boltayev>

Metodologia

Levenstein distance - samples



```
best match for amazen - amazon (83.33)  
best match for gogl - google (80.00)  
best match for adidos - addidy (66.67)  
best match for netflex - netflix (85.71)  
best match for mango - mojang (72.73)  
best match for mustard - cpmstar (71.43)
```

Figure: Best matches for sample words

Metodologia

Levenshtein distance - distribution




Figure: Distribution

Metodologia

Levenstein distance - low ratios

	joined_domains	best_ratio
857	155-166-184-94	29.629630
963	119984852325100025-founders	32.432432
1058	1000020300389264567812345675-admin-revolution	32.727273
1196	ck3771548791586435298568858-expert-rebelution	29.090909
1230	10000012445567856336214-fb-pageevent	27.272727
1248	15-162-241-69	30.769231
1329	107-11-172-39	30.769231

Figure: Low ratios examples

Metodologia

Levenstein distance - high ratios (phishing)

	joined_domains	best_match	best_ratio	URLs
3346	paypai	paypal	83.333333	http://paypai.su/signin
3389	fastel	fastly	83.333333	http://www.fastel.ph/TO/authorize_client_id:n8...
3438	amazow	amazon	83.333333	https://amazow.gq/pc
4022	inatel	intel	90.909091	https://mail.inatel.pt/owa/auth/logon.aspx?rep...
4369	vidiaa	nvidia	83.333333	https://www.aoyo.co.jp.vidiaa.com/clinet/index...
4371	drv	1drv	85.714286	https://uz9zoiz9vqbutkpvdy0tg-on.drv.tw/www.m...
4639	aws3	aws	85.714286	https://laliqidacion.dev03.aws3.net/wp-conten...
5020	onedrive-pl	onedrive	84.210526	https://www.onedrive-pl.cyou/excel/document/wo...

Figure: High ratios phishing examples

Metodologia

Levenstein distance - high ratios (safe)

	joined_domains	best_match	best_ratio	URLs
2409	intercomp	intercom	94.117647	https://www.intercomp.ru/
2627	netflex	netflix	85.714286	https://www.netflex.nl/contact/
3409	baka	aka	85.714286	https://www.baka.ca/plans
3513	mdb	tmdb	85.714286	https://www.mdb.co.jp/nextcareer/
3765	ngbank	nubank	83.333333	https://www.ngbank.com/national-grand-bank/rates
4248	oncloud	cloud	83.333333	https://www.oncloud.io/the-cloud-demystified.php
4980	ferntrust	entrust	87.500000	https://www.ferntrust.com/bouquets.html
5398	antenor	tenor	83.333333	https://www.antenor.fr/notre-savoir-faire/
5575	unt	ubnt	85.714286	http://govinfo.library.unt.edu/911/about/bio_l...
6009	eye	eye4	85.714286	https://www.eye.co.jp/
6212	cimb	cib	85.714286	https://www.cimb.com/
6496	weatherite	weather	82.352941	https://www.weatherite.com/Home/Services

Figure: High ratios safe examples

Metodologia

Levenstein distance - 100 ratios (phishing)

	joined_domains	best_match	best_ratio	URLs
210	google	google	100.0	https://docs.google.com/forms/d/e/1FAIpQLScl0W...
212	google	google	100.0	https://docs.google.com/forms/d/e/1FAIpQLSfvqk...
219	blogspot	blogspot	100.0	https://norwayposten.blogspot.com/2021/02/blog...
223	office	office	100.0	https://forms.office.com/Pages/ResponsePage.as...
224	windows	windows	100.0	https://3deya6i.blob.core.windows.net/hjvhvh/A...
313	github	github	100.0	https://github.com/HotarusCorp/BancoPichincha
324	google	google	100.0	https://sites.google.com/view/paypal-customer-...
340	google	google	100.0	https://docs.google.com/forms/d/e/1FAIpQLSfQQZ...
353	google	google	100.0	https://sites.google.com/view/ffjhgfmbgbpdjbvd...
358	googleapis	googleapis	100.0	https://firebasestorage.googleapis.com/v0/b/tt...

Figure: 100 ratio

Metodologia

Wybór cech


- ▶ Dla zaimplementowanych cech chemy wybrać te najbardziej informatywne.
- ▶ Obliczamy własna funkcje kosztu i kryterium informacyjne.
- ▶ Ze zbioru zaimplementowanych featurów iteracyjnie usuwaliśmy te których usuniecie zwiększało kryterium informacyjne.

Threshold

Skorzystalismy z funkcji kosztu oszacowujac najlepszy threshold.

Metodologia

Wybor thresholdu dla regresji liniowej




Wyniki

Performance uzyskanego modelu regresji logistycznej (treningowy dataset)

Mean Accuracy: 0.93

Mean custom cost per sample: 0.1012

Phishing recall: 0.96




Wyniki

Performance uzyskanego modelu regresji logistycznej (testowy dataset)

Mean Accuracy: 0.874

Phishing recall: 0.80

Phishing precision: 0.95



Wyniki


Performance uzyskanego modelu regresji logistycznej (testowy dataset)

	feature	importance
0	num_freaky_tld	4.860046
1	is_www	4.349569
2	https	1.583847
3	is_com	1.156137
4	suffix_num	1.050061
5	popular_suffix_in_domain	0.978251
6	popular_domain_in_subdomain	0.833342
7	popular_domain_in_domain	0.802704
8	domains_num	0.793045
9	popular_suffix_in_subdomain	0.730442
10	has_com	0.648902
11	has_org	0.529563
12	dash_num	0.494541
13	digits_in_domain	0.372823
14	subdomain_num	0.362775
15	digits_in_subdomain	0.306230
16	slash_num	0.187468
17	num_country_tld_in_subdomain	0.185243
18	num_country_tld_in_domain	0.101961
19	domain_length	0.065161
20	digits_in_suffix	0.034271
21	num_country_tld_in_suffix	0.031318
22	length	0.013097
23	dot_num	0.013061
24	digits_in_url_num	0.006827

Figure: Feature importance

Metodologia

Wybor thresholdu dla random forest classifier




Wyniki

Performance uzyskanego modelu random forest classifier (testowy dataset)

Mean Accuracy: 0.9690

Mean custom cost per sample: 0.1126

Phishing recall: 0.9



Wyniki

Performance uzyskanego modelu random forest classifier (testowy dataset)

Mean Accuracy: 0.889

Phishing recall: 0.93

Phishing precision: 0.83

